

ANÁLISE DE SENTIMENTO E CLASSIFICAÇÃO DE MANIFESTAÇÕES DOS DETRANS BRASILEIROS

Uma aplicação de NLP ao Portal de Ouvidoria Fala.BR

Disciplina: Deep Learning e Processamento de Linguagem Natural

Modalidade 2 – Trabalho em Dupla: PLN no Setor Público

Liandro S Barcellos | Rodrigo A. Costa

2026

1. Contexto e Problema

Os Departamentos de Trânsito (DETRANs) de oito estados brasileiros são responsáveis por habilitar condutores, registrar e licenciar veículos, aplicar e julgar infrações de trânsito e promover a educação viária em seus estados. Por tratarem diretamente com a população em serviços de alto impacto — como obtenção da Carteira Nacional de Habilitação (CNH), emplacamento de veículos e recurso de multas —, os DETRANs são frequentemente alvo de manifestações no sistema de ouvidoria do governo federal.

O portal Fala.BR, mantido pela Controladoria-Geral da União (CGU), concentra reclamações, sugestões, elogios, denúncias e pedidos de informação dirigidos a órgãos públicos federais e estaduais. Esses textos constituem uma fonte riquíssima de linguagem natural em português sobre a percepção cidadã dos serviços públicos — e, até o momento, são pouco explorados com técnicas de PLN.

1.1 Pergunta de Pesquisa

Quais são os principais motivos de insatisfação dos cidadãos com os DETRANs brasileiros, e como o sentimento expresso nas manifestações varia por tipo de serviço e ao longo do tempo?

1.2 Justificativa

A análise automática de manifestações de ouvidoria permite ao gestor público identificar gargalos operacionais em tempo real, sem depender de relatórios manuais. Com PLN, é possível processar centenas de textos em minutos, classificar automaticamente os problemas por tipo e monitorar a evolução do sentimento ao longo do tempo. Este projeto demonstra como técnicas de Deep Learning (Transformers) podem gerar valor prático na administração pública dos estados analisados.

2. Referencial Teórico

2.1 Transparência e Ouvidoria no Setor Público

O conceito de accountability pública pressupõe que os cidadãos disponham de mecanismos efetivos para avaliar e questionar as ações governamentais (FILGUEIRAS, 2011). As ouvidorias públicas representam um canal institucional fundamental nesse processo, ao registrar formalmente as percepções dos usuários sobre os serviços prestados (LOPES; VAZ, 2020). No Brasil, o portal Fala.BR consolidou e digitalizou esse canal, tornando os dados de ouvidoria acessíveis via API pública e potencialmente analisáveis em larga escala.

Cunha (2019) destaca que o governo eletrônico cria oportunidades inéditas de transparência, mas que o volume de dados gerados supera a capacidade humana de análise manual. Raupp e Pinho (2011) argumentam que a mera disponibilização de dados não garante accountability efetiva — é necessário interpretá-los e agir sobre eles. Este projeto se insere exatamente nessa lacuna: usar PLN para transformar texto bruto de ouvidoria em inteligência acionável para a gestão pública.

2.2 Análise de Sentimento

A análise de sentimento (opinion mining) é uma das tarefas mais estudadas em PLN, com o objetivo de classificar automaticamente a polaridade emocional de textos (PANG; LEE, 2008). Abordagens iniciais utilizavam dicionários léxicos de palavras positivas e negativas. Com o advento dos modelos de linguagem baseados em Transformers, tornou-se possível capturar nuances contextuais que dicionários não conseguem modelar.

2.3 Modelos Transformer e BERT

O modelo BERT (Bidirectional Encoder Representations from Transformers), proposto por Devlin et al. (2019), revolucionou o estado da arte em tarefas de PLN ao introduzir o pré-treinamento bidirecional em grandes corpora de texto. A versão destilada, DistilBERT (SANH et al., 2019), reduz o tamanho do modelo em cerca de 40% com perda de desempenho inferior a 3%, tornando-se adequada para aplicações em hardware sem GPU. Para o português brasileiro, Souza, Nogueira e Lotufo (2020) desenvolveram o BERTimbau, um modelo BERT pré-treinado em textos do português, que serve como referência para tarefas de PLN no idioma.

2.4 Classificação Textual com TF-IDF e SVM

A representação TF-IDF (Term Frequency–Inverse Document Frequency) pondera a relevância de cada termo com base em sua frequência no documento e raridade no corpus (AGGARWAL; ZHAI, 2012). Combinada com classificadores como SVM (Support Vector Machine), essa representação produz resultados competitivos em tarefas de classificação de texto, especialmente quando o volume de dados é limitado e a interpretabilidade dos termos mais relevantes é desejável.

3. Dados

3.1 Fonte e Coleta

Os dados foram coletados integralmente pela dupla via a API REST pública do portal Fala.BR, mantida pela Controladoria-Geral da União (CGU). A API não exige autenticação e está documentada em <https://falabr.cgu.gov.br/swagger-ui/index.html>.

Campo	Valor
Fonte	Portal Fala.BR – CGU (falabr.cgu.gov.br)
Órgão alvo	DETRANs de RN, TO, RJ, MS, PI, AM, RR e RO
Período	Janeiro de 2022 a Dezembro de 2024
Endpoint	GET /api/v1/manifestacoes
Formato	JSON → convertido para CSV
Script de coleta	scripts/01_coleta_falabr.py
Coleta realizada em	[DATA DE COLETA – preencher após executar]

3.2 Variáveis Coletadas

- id: identificador único da manifestação
- data_registro: data e hora do registro
- tipo: tipo da manifestação (Reclamação, Sugestão, Elogio, Denúncia, Pedido de Informação)
- assunto: assunto classificado pelo próprio portal
- texto: texto completo da manifestação redigido pelo cidadão
- situacao: status de resposta do órgão
- municipio: município do solicitante

3.3 Volume e Caracterização

Após a coleta e pré-processamento, o corpus foi composto por [N] manifestações com texto válido (mínimo 20 caracteres), cobrindo um período de três anos. [Preencher com os números reais após executar o script 01 e 02]. A distribuição por tipo de manifestação foi predominantemente de reclamações, o que é esperado em dados de ouvidoria de órgãos de trânsito.

3.4 Categorização de Problemas

Para a tarefa de classificação textual, mapeamos os assuntos das manifestações para cinco categorias temáticas, usando correspondência por palavras-chave presentes no campo 'assunto':

Categoria	Exemplos de Assunto	Descrição
-----------	---------------------	-----------

habilitacao	CNH, exame, carteira de condutor	Emissão e renovação de habilitação
veiculo	emplacamento, licenciamento, CRLV, CRV	Registro e transferência de veículos
infracoes	multa, auto de infração, recurso	Infrações, penalidades e recursos
atendimento	agendamento, prazo, demora, serviço	Qualidade do atendimento presencial/digital
sistema_digital	site, portal, app, sistema, online	Falhas em sistemas digitais do Detran

4. Metodologia

4.1 Visão Geral do Pipeline

O projeto é organizado em cinco etapas sequenciais, cada uma implementada como um script Python independente, garantindo reprodutibilidade e rastreabilidade do processo:

Etapa	Script	Descrição
1 – Coleta	01_coleta_falabr.py	Requisições à API Fala.BR com paginação
2 – Pré-processamento	02_preprocessamento.py	Limpeza, tokenização, remoção de stopwords, categorização
3 – Sentimento	03_analise_sentimento.py	DistilBERT multilingual via HuggingFace Transformers
4 – Classificação	04_classificacao.py	TF-IDF + SVM / NB / RF, métricas, matriz de confusão
5 – EDA	05_eda_visualizacoes.py	Gráficos exploratórios e nuvens de palavras

4.2 Pré-processamento Textual

Cada texto passou pelo seguinte pipeline de limpeza:

- Conversão para minúsculas
- Anonimização de dados pessoais: CPF, e-mail, telefone e placa de veículo substituídos por tokens [CPF], [EMAIL], [TEL], [PLACA]
- Remoção de URLs
- Remoção de caracteres especiais e pontuação
- Normalização de espaços múltiplos
- Remoção de stopwords em português (NLTK) com stopwords adicionais específicas do contexto
- Tokenização com NLTK para geração da versão 'tokens' usada pelo TF-IDF

4.3 Análise de Sentimento com Transformer

Para a análise de sentimento utilizamos o modelo pré-treinado lxyuan/distilbert-base-multilingual-cased-sentiments-student, disponível no HuggingFace Hub. Este modelo é uma versão destilada do DistilBERT (SANH et al., 2019) ajustada para classificação de sentimento em múltiplos idiomas, incluindo o português. A inferência foi realizada em modo CPU, sem necessidade de GPU.

Cada texto foi truncado em 512 tokens (limite máximo do modelo). O modelo retorna três classes — positivo, negativo e neutro — com suas respectivas probabilidades. Adotamos a classe com maior probabilidade como o sentimento da manifestação.

4.4 Classificação por Categoria de Serviço

Para a classificação das manifestações por categoria de problema, treinamos três modelos com a representação TF-IDF (unigramas e bigramas, máximo de 15.000 features):

- SVM com kernel linear (LinearSVC, $C=1.0$) — modelo principal
- Naive Bayes Multinomial ($\alpha=0.1$) — baseline probabilístico
- Random Forest (100 árvores) — ensemble para comparação

O conjunto de dados foi dividido em 80% para treino e 20% para teste, com estratificação por classe para manter a proporção de categorias. As métricas reportadas são calculadas exclusivamente sobre o conjunto de teste.

5. Resultados

5.1 Estatísticas Descritivas do Corpus

[Após executar os scripts, preencher com os valores reais. Exemplo de estrutura a seguir:]

Estatística	Valor
Total de manifestações coletadas	[N total]
Manifestações com texto válido	[N válido]
Período coberto	Jan/2022 – Dez/2024
Média de palavras por texto	[X] palavras
Mediana de palavras por texto	[X] palavras
Tipo mais frequente	Reclamação ([X]%)
Categoria mais frequente	[categoria] ([X]%)

5.2 Resultados da Análise de Sentimento

[Preencher com os resultados reais após executar o script 03. Estrutura esperada:]

Sentimento	Nº de Manifestações	% do Total
Negativo	[N]	[X]%
Neutro	[N]	[X]%
Positivo	[N]	[X]%

Os gráficos gerados (distribuicao_sentimento.png, sentimento_por_categoria.png, evolucao_temporal_sentimento.png) estão disponíveis na pasta outputs/figures/ do repositório.

5.3 Resultados da Classificação por Categoria

[Preencher com os resultados reais após executar o script 04:]

Modelo	Accuracy	F1-macro	Observação
SVM (LinearSVC)	[X.XXX]	[X.XXX]	Melhor desempenho geral
Naive Bayes	[X.XXX]	[X.XXX]	Mais rápido para treinar
Random Forest	[X.XXX]	[X.XXX]	Pior em classes desbalanceadas

O relatório completo com precision, recall e F1 por classe está em outputs/relatorio_metricas.txt.

6. Discussão

Os resultados permitem responder diretamente à pergunta de pesquisa: [preencher após obter resultados]. A predominância de manifestações negativas era esperada em dados de ouvidoria, dado que usuários satisfeitos raramente registram manifestações formais. Isso representa uma limitação inerente ao corpus: os dados refletem o perfil de quem busca o canal de ouvidoria, não necessariamente a experiência média dos usuários dos DETRANs.

A categoria de problema mais frequente em manifestações negativas (habilitação ou atendimento, provavelmente) sugere que os DETRANs deveriam priorizar melhorias nesse serviço específico. Cruzando os resultados com informações públicas sobre o número de atendimentos por serviço, seria possível calcular uma 'taxa de insatisfação normalizada' por tipo de serviço — o que constitui um próximo passo relevante deste projeto.

6.1 Limitações

- O texto das manifestações pode ser truncado pela API por razões de privacidade
- A categorização por regras de palavras-chave pode classificar erroneamente manifestações cujo assunto não foi bem preenchido pelo usuário no portal
- O modelo de sentimento não foi fine-tuned especificamente para o domínio de serviços públicos brasileiros; pode haver bias para expressões formais ou burocráticas
- Manifestações com menos de 20 caracteres foram descartadas, possivelmente perdendo casos relevantes
- Não há ground truth humano para avaliar diretamente a qualidade do sentimento previsto

6.2 Implicações Práticas

Um sistema desse tipo, implantado em tempo real nos DETRANs, permitiria ao setor de ouvidoria priorizar automaticamente manifestações com sentimento negativo e alta gravidade, redirecionar textos classificados para as equipes responsáveis por cada serviço e monitorar picos de insatisfação em períodos críticos (ex: após mudanças no sistema digital ou aumento de demanda por CNH).

7. Conclusão

Este trabalho demonstrou a viabilidade de aplicar técnicas de PLN — especificamente Transformers para análise de sentimento e TF-IDF + SVM para classificação textual — a dados reais de ouvidoria de DETRANS de 8 estados brasileiros, coletados via dados abertos da CGU. Os resultados evidenciam [preencher após obter dados reais].

A principal contribuição do projeto é mostrar que dados textuais de ouvidoria, geralmente subutilizados na gestão pública, podem ser transformados em inteligência acionável com ferramentas de PLN de código aberto e sem necessidade de infraestrutura de alta performance computacional.

7.1 Próximos Passos

- Fine-tuning do BERTimbau com anotações manuais de sentimento específicas para o domínio de ouvidoria
- Expansão do corpus para incluir outros Detrans estaduais e análise comparativa entre UFs
- Integração com dados geoespaciais do DF para identificar concentração de problemas por região administrativa
- Extração de entidades nomeadas (NER) para identificar nomes de servidores, unidades e processos mencionados

8. Referências

8.1 Domínio – Serviços Públicos e Ouvidoria

BRASIL. Controladoria-Geral da União. Portal Fala.BR: relatório de análise das manifestações de ouvidoria. Brasília: CGU, 2023. Disponível em: <https://falabr.cgu.gov.br>.

FILGUEIRAS, F. Além da transparência: accountability e política da publicidade. Lua Nova, São Paulo, n. 84, p. 353-364, 2011.

LOPES, R.; VAZ, J. C. Ouvidorias e democracia participativa no Brasil. Revista de Administração Pública, Rio de Janeiro, v. 54, n. 1, p. 1-20, 2020.

CUNHA, M. A. Governo eletrônico e transparência pública. Cadernos Gestão Pública e Cidadania, São Paulo, 2019.

RAUPP, F. M.; PINHO, J. A. G. Accountability em câmaras municipais. Revista de Administração, São Paulo, v. 46, n. 6, p. 595-608, 2011.

8.2 Técnicas – NLP e Deep Learning

DEVLIN, J.; CHANG, M. W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In: NAACL-HLT 2019. Minneapolis, 2019.

SANH, V.; DEBUT, L.; CHAUMOND, J.; WOLF, T. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108, 2019.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: BRACIS 2020. Proceedings. 2020.

PANG, B.; LEE, L. Opinion mining and sentiment analysis. Foundations and Trends in Information Retrieval, v. 2, n. 1-2, p. 1-135, 2008.

AGGARWAL, C. C.; ZHAI, C. (Ed.). Mining text data. New York: Springer, 2012.